

Contents

Appunti ACSO	2
I principi fondamentali	2
Data path	3
Codifica delle istruzioni	3
Architettura LOAD/STORE	3
Interruzioni (interrupt)	3
La gerarchia di memoria	3
Indirizzi di memoria principale	4
Bus di sistema	4
Esempio: operazione di lettura da memoria	4
MIPS assembler	4
Sintassi	4
Direttive	4
Registri	5
Istruzioni	5
Modalità di indirizzamento	8
Etichette	8
Traduzione da C a MIPS	8
Modello di memoria	9
Syscall	9
Dimensioni delle variabili	9
Classi di variabili	9
Variabili globali	9
Variabili locali	10
Parametri	10
Variabili dinamiche	10
Funzioni	10
Salvataggio dei registri	10
Gestione dello stack	11
Funzioni foglia	11
Valutazioni espressioni algebriche	11
Flusso di compilazione e assemblaggio	12
L'assemblaggio	12
Tabella dei simboli	12
Assemblaggio e tabella di rilocazione	12
Il formato oggetto	12
Indirizzamento di dati statici	13
Simboli rilocabili, locali ed esterni	13
Il linker	13
Regole di correzione dei riferimenti nei moduli	13
Caricamento ed esecuzione del programma	13
Librerie dinamiche	14
Livello logico-digitale	14
I segnali	14
I circuiti sequenziali	14
Algebra di commutazione	14
Operatori	14
Funzione combinatoria	15
Porte logiche	15
Costo e velocità delle porte	15
Analisi e sintesi di reti combinatorie	16
Sintesi	16
I blocchi funzionali combinatori	16
Multiplexer	16
Demultiplexer	16
Decoder	16
Comparatore	17
Shifter combinatorio	17

Half adder	17
Full adder	17
Addizionatore a k bit in binario naturale intero	17
Unità aritmetico logica	18
Bistabili	18
Bistabili SR asincroni	18
Segnale di sincronizzazione	19
Bistabili sincroni	19
Bistabile SR sincrono (SR-latch)	19
Bistabile D sincrono (D-latch)	19
Flip-flop D master-salve	19
Flip-flop D edge-triggered	21
Blocchi funzionali sequenziale	21
Il registro parallelo	21
Registro a scorrimento	22
Banchi di registri e memoria	22
Circuito di pilotaggio	22
Banchi di registri	22
Memoria	23
Tecnologie di memoria	23
Il processore	24
Esecuzione di una istruzione	24
Esecuzione di istruzioni aritmetico logiche	24
Esecuzione di istruzioni di load e store	24
Istruzione di salto condizionato	24
Istruzioni di salto incondizionato	25
Realizzazione del processore a ciclo singolo	25
CPU a singolo ciclo e multiciclo	25
Pipeline	25
Conflitti nella pipeline	27
Conflitto sui dati	27
Conflitto di controllo	31
La gerarchia delle memorie	32
Memoria Cache	33
Definizioni	33
Organizzazione delle memoria cache	33
Confronto tra diverse organizzazione di cache	36
Strategie di scrittura di un blocco	37
Prestazioni	37
Cache multilivello	37

Appunti ACSO

I principi fondamentali

I processori eseguono le istruzioni in maniera sequenziale (non vedremo la Out of Order Execution). Il processore contiene una sezione di controllo che controlla l'esecuzione leggendo le istruzioni dalla memoria. I vari programmi da eseguire sono salvati in una memoria.

L'architettura di riferimento è l'architettura di Von Neumann. Esso contiene:

- Processore
 - Sezione di controllo
 - ALU
 - Registri
- Memoria
- Interfacce I/O
- Bus che collega i vari componenti sopra elencati

I registri sono delle piccole celle di memoria che il processore usa per salvare dati utili. Ogni registro ha una dimensione massima specificata in bit. I registri che studieremo saranno quelli a 32 bit.

Viene detta parola del processore la lunghezza dei suoi registri, ossia la lunghezza massima della sequenza di bit che può gestire.

Esistono dei registri particolare:

- PC (Program Counter): contiene l'indirizzo della prossima istruzione in memoria
- IR (Instruction Register): contiene l'intera istruzione da eseguire

Il ciclo di esecuzione di un'istruzione è divisa nelle seguenti fasi:

- fetch: viene presa dalla memoria attraverso il bus l'istruzione puntata dal program counter e incrementalo nel frattempo (memoria più lenta del processore)
- decode: decodifica l'istruzione e prepara l'esecuzione prelevando gli operandi
- execute: esegui e memorizza i risultati

I vari processori si differenziano in base alla lunghezza delle istruzioni che usano (può essere una singola parola (RISC) oppure più (CISC)).

Data path

Il data path è formato da registri e da ALU. I registri sono divisi in:

- utilizzabili dall'assembler
- di supporto per altri componenti (es.: 3 registri di supporto dell'ALU (sorgente, sorgente, destinazione))

Abbiamo due classi di istruzioni:

- Prendono registri e memorizzano in altri registri (registro-registro)
- Gestiscono lo spostamento da registri a memoria (registro-memoria)

L'esecuzione di una istruzione registro-registro viene detta ciclo di data path. Il ciclo di data path è collegato al ciclo di clock.

Codifica delle istruzioni

Ogni istruzione è divisa in codice operativo e campi (field). Il codice operativo indica il tipo di operazione. I campi vengono usati per gli operandi dell'istruzione.

Le modalità di indirizzamento descrivono le diverse modalità attraverso le cui far riferimento agli operandi nelle istruzioni.

Architettura LOAD/STORE

Il numero di registri ad uso generale non è abbastanza grande per mantenere tutte le variabili di un programma. Ad ogni variabile viene quindi assegnata una locazione in memoria nella quale salvare il contenuto del registro che la rappresenta quando deve essere usato per altro.

Poiché gli operandi delle istruzioni possono provenire solamente dai registri ad uso generale, servono delle istruzioni di caricamento e salvataggio a memoria. Da qui il nome dell'architettura.

Interruzioni (interrupt)

Il normale flusso dei programmi può essere interrotto attraverso le interruzioni. Quando un dispositivo esterno vuole richiedere l'attenzione del processore, esso attiva un segnale hardware (segnale di interrupt) per notificarlo.

Il check degli interrupt viene fatto alla fine dell'esecuzione di un'istruzione ma prima del fetch della successiva. Se viene trovato un segnale di interrupt, il processore interrompe la normale esecuzione del programma ed esegue la richiesta. Una volta gestita il processore torna ad eseguire normalmente il suo programma.

La gerarchia di memoria

E' divisa in una gerarchia (dalla più veloce alla più lenta):

- Registri
- Cache (L1, L2, L3)
- Memoria fisica: RAM (es. DDR-SDRAM)
- Memoria a stato solido (SSD)
- Memoria virtuale: basata su file (HDD)

Indirizzi di memoria principale

La memoria principale è suddivisa in celle. La dimensione di una cella è chiamata parola, come anche il numero massimo di bit che il processore può gestire. La parola di memoria non per forza avrà la stessa dimensione della parola del processore.

Nel MIPS useremo una parola di memoria di 8 bit (memoria indirizzabile al byte). Di conseguenza una parola MIPS è lunga 4 parole di memoria.

Il tempo di indirizzamento di ogni singola parola è uguale.

L'insieme di tutte le celle di memoria indirizzabili con 1 parola di processore è detto spazio di memoria: per una parola di 32 bit si ha uno spazio di memoria di 4 GB.

Bus di sistema

Un bus è un insieme di fili. Ogni filo trasferisce un bit. I vari fili sono suddivisi in categorie:

- Bus dati: comprende le linee usate per trasferire dati da/verso memoria. La dimensione del bus dati deve essere abbastanza da garantire il trasferimento contemporaneo di una o più parole di memoria
- Bus indirizzi: comprende le linee sulle quali la CPU procede a trasmettere gli indirizzi di memoria delle risorse
- Bus di controllo: comprende le linee su cui transitano le informazioni ausiliarie per la corretta definizione delle operazioni e per sincronizzare CPU e memoria

Il bus può essere utilizzato per un solo trasferimento alla volta: in ogni istante solo due entità possono comunicare (master - slave). Il master è il processore, gli slave sono le periferiche. Il processore regola l'accesso delle varie periferiche. L'unico filo che può essere usato senza permesso del processore è quello di interrupt request.

L'architettura a bus singolo è molto flessibile e semplice. I dispositivi, però, hanno velocità diverse. Serve, quindi, un meccanismo di sincronizzazione tra le varie periferiche.

Esempio: operazione di lettura da memoria

1. CPU fornisce l'indirizzo della parola desiderata sul bus indirizzi e richiede la lettura sul bus di controllo
2. Quando la memoria ha completato la lettura della parola richiesta, il dato viene trasmesso sul bus dati

MIPS assembler

Il linguaggio assembler è simbolico. E' il primo livello di astrazione prima del linguaggio macchina.

Un programma è composto da più file (oggetti). Il compito di "collegare" i vari oggetti è delegato al linker.

L'assembler non istruisce che effettuano un controllo di flusso come inteso in C. L'unico strumento che ha è il jump/branch che permette di saltare da un'istruzione all'altra.

Sintassi

Nel MIPS i registri sono numerati da 0 a 31 e hanno dei nomi simbolici. Vengono identificati dal simbolo \$. Mettere un registro tra parentesi tonde effettua un'operazione di indirizzamento. Il primo registro nei field è quasi sempre la destinazione del risultato dell'istruzione.

Direttive

I comandi che iniziano con . sono direttive del preprocessore. Esse sono:

- `.text` o `.data`: indica che le linee successive sono istruzioni o dati
- `.align n`: specifica l'allineamento a 2^n bit
- `.globl main`: indica che l'etichetta `main` è visibile anche in altri file (visibilità globale)
- `.ascii`: specifica un'area di memoria che contiene una stringa ASCII terminata da `\0`
- `.space n`: riserva uno spazio di n byte
- `.word n`: equivalente a `.space 4` e settare a `n`
- `.half n`: equivalente a `.space 2` e settare a `n`
- `.byte n`: equivalente a `.space 1` e settare a `n`
- `.eqv A, n`: equivalente alla `#define` del C

Registri

Essi sono 32, numerati da 0 a 31 (occupa 5 bit). Ogni istruzione, quindi, può usare 3 registri alla volta. Gli operandi delle istruzioni devono essere prima salvati nei registri.

Registri referenziabili:

- \$0: contiene sempre 0
- \$1/\$at: riservato
- \$v0 e \$v1: usati per risultati di funzioni e calcolo espressioni
- \$a0 - \$a3: usati per il passaggio di argomenti
- \$t0 - \$t7: variabili temporanee
- \$s0 - \$s7: variabili da preservare
- \$k0 e \$k1: riservati al kernel
- \$gp: global pointer (punta ad area di dati globale/statica)
- \$sp: stack pointer
- \$fp: frame pointer (puntatore ai frame funzione; in aiuto a \$sp)
- \$ra: return address utilizzato nelle chiamate di funzione

Registri non referenziabili:

- \$pc: program counter
- \$hi: registro per moltiplicazione/divisione
- \$lo: registro per moltiplicazione/divisione

Istruzioni


Le istruzioni si dividono in 4 categorie:

1. istruzioni aritmetico logiche
2. istruzioni di trasferimento da/verso memoria (ad es. `lw` e `sw`)
3. istruzioni di salto condizionato/incondizionato
4. istruzioni di ingresso/uscita (non fornite da tutti gli assembler)


Le istruzioni sono tutte lunghe massimo 32 bit. I 6 bit più significativi si chiamano “codice operativo” (OPCODE) e indica il tipo di istruzione.

In MIPS ci sono 3 tipi di istruzioni:


- tipo R: istruzioni aritmetico-logiche; strutturate in:



- tipo I: istruzioni di accesso alla memoria o contenenti costanti



- tipo J: salto



Sintassi:

istruzione field1, field2, field3 # comment

La lista completa di tutte le istruzioni non è riportata qui. Può essere trovata nella cartella con il materiale del corso.

Istruzioni aritmetico-logiche

istruzione	campo	campo	campo
add	rd	rs	rt
addu	rd	rs	rt
addi	rd	rs	const
addui	rd	rs	const
sub	rd	rs	rt
subu	rd	rs	rt
subi	rd	rs	const
subui	rd	rs	const
mult	rs	rt	-
multu	rs	rt	-
div	rs	rt	-
divu	rs	rt	-

Le istruzioni immediate (*i) hanno la peculiarità di prendere una costante al posto di un secondo registro. Per come è strutturato il formato delle istruzioni immediate, la costante sarà di massimo 2^{16} .

Il registro di destinazione della `mult` è implicito: il risultato viene salvato in `$hi` (32 cifre più significative) e `$lo` (32 cifre meno significative). Per spostare il risultato da questi due registri viene usato `mfhi rd` e `mflo rd`. Stessa cosa vale per la divisione solo che il quoziente è posto nel registro `$lo`, mentre il resto in `$hi`.

Trasferimenti in memoria

istruzione	campo	campo
lw	rt	const(rs)
sw	rt	const(rs)
la	rt	const

La parte `const(rs)` serve a calcolare l'indirizzo di memoria a cui si fa riferimento. L'indirizzo di memoria è pari a `const + indirizzo contenuto in rs`. Per come è strutturata il tipo di istruzione I, posso caricare/salvare nell'intervallo $[-2^{15} ; +2^{15} - 1]$ rispetto al registro base.

In memoria una `lw` o una `sw` avranno questo formato:

6	5	5	16
-----	-----	-----	-----
OPCODE	rs	rt	const
-----	-----	-----	-----

L'istruzione `la` è una pseudo istruzione: poiché gli indirizzi sono di 32 bit, non è possibile specificare un intero indirizzo in un'istruzione. L'assemblatore, allora, espande la `la` in 2 istruzioni:

- si utilizza lui `$rt const` per caricare i 16 bit più significativi in `$at` (mettendo a 0 gli altri 16 bit meno significativi)
- si utilizza un'altra istruzione (o*ri* un esempio) per caricare gli altri bit meno significativi e spostare tutto nel registro di destinazione

Un'altra pseudo istruzione simile è `li $rt, const`.

L'ordinamento dei byte di una parola non è da dare per scontato:

- big-endian: ordinamento da sinistra a destra
- little-endian: ordinamento da destra a sinistra

Il MIPS può operare con entrambe le modalità.

Load e store con indirizzi simbolici

Nelle chiamate a `lw` e `sw` si può omettere il registro base. In quel caso verrà usato `$gp` e l'offset verrà calcolato dal linker.

```
.data
...
A: .word
...
```

```
.text
...
    lw $t0, A
    # viene assemblato in
    #    lw $t0, %gp_rel(A)($gp)
    # dove %gp_rel(A) è una direttiva del linker che calcola l'offset di A da
    # $gp
```

Anche `la` possiede una forma simile: i bit più significativi e meno significativi non sono calcolati dal compilatore, ma il compito viene delegato al linker:

```
.data
...
A: .word
...

.text
...
    la $t0, A
    # viene assemblato in:
    #    lui $t0, %hi(A)
    #    addiu $t0, %lo(A) # oppure ori $t0, %lo(A)
    # dove come prima %hi(A) e %lo(A) sono direttive del linker
```

Queste forme vanno usate solo con valori dichiarati con `.word`, `.half` e `.byte`.

Per più dettagli vedi la sezione sulla compilazione e assemblaggio.

Istruzioni logiche

istruzione	campo	campo	campo
and	rd	rs	rt
or	rd	rs	rt
nor	rd	rs	rt
sll	rd	rs	sa
srl	rd	rs	sa

`sll` di 1 bit equivale a moltiplicare per 2. `srl` di 1 bit equivale dividere per 2.

L'istruzione `not` viene eseguita con usando `nor $rd $rs $0`.

Esistono anche le varianti immediate per `and`, `or` e `nor`.

Istruzioni di modifica del flusso

Le istruzioni di modifica del flusso servono a forzare la modifica del `$pc`, rompendo il flusso sequenziale standard. Il salto condizionato viene chiamato `branch`, quello incondizionato `jump`.

Branch

Le istruzioni di `branch` hanno tutte la forma:

`branch_condizione rs, rt, offset`

Le istruzioni di `branch` sono di tipo I. Avrò quindi a disposizione un salto di $[-2^{15} ; +2^{15} - 1]$ (salvato a complemento a 2) parole. Il salto però viene effettuato relativo al program counter. Il principio di località degli indirizzi, però, ci viene in aiuto: i programmi lavorano solo su segmenti vicini di indirizzi. La probabilità di saltare verso indirizzi più distanti di $2^{15}-1$ è molto bassa.

istruzione	campo	campo	campo	condizione
beq	rs	rt	offset	<code>rs == rt</code>
bne	rs	rt	offset	<code>rs != rt</code>

L'assemblatore, a un'etichetta messa nel campo offset, sostituisce $(L-(PC+4))/4$.

Per verificare diseuguaglianze usiamo le seguenti istruzioni ausiliarie. Esse caricano 1 nel registro destinazione se la condizione è avverata e 0 altrimenti.

istruzione	campo	campo	campo	condizione
slt	rd	rs	rt	rs < rt
sltu	rd	rs	rt	rs < rt

Queste istruzioni sono di tipo R. Esistono anche le varianti immediate di queste istruzioni.

Jump

Sono possibili 3 salti assoluti:

istruzione	campo
j	offset
jal	offset
jr	rs

Nel campo offset rizzo posso salvare fino a 26 bit. Poiché le istruzioni hanno allineamento 4, i due bit meno significativi saranno sempre 00. Posso, quindi, ignorare questi due bit salvando escludendo i due bit meno significativi ottenendo un salto totale di 2^{28} indirizzi (ossia 2^{26} parole). A runtime il processore farà uno shift di due a sinistra il campo indirizzo e lo concatenerà ai 4 bit più significativi del program counter, ottenendo l'indirizzo di salto.

Per saltare a indirizzi superiori a 2^{28} Byte devo usare la **jr**.

La **jal** salva $\$pc + 4$ nel registro **\$ra** prima di saltare. Essa viene usata per implementare la chiamata a funzione. La **jr** invece viene usata per implementare il ritorno al chiamante (**jr \$ra**).

Nota bene: anche i salti hanno delle restrizioni sull'indirizzo (26 bit dedicati)

Gestione delle costanti

Se usiamo costanti di 32 bit, l'assemblatore deve fare 2 passi per caricarla: deve separare la costanti in due parti di 16 bit e trattarle con due istruzioni separate. Proprio come **la**, esiste la pseudo istruzione **li \$rs, const** che esegue gli stessi passaggi.

Modalità di indirizzamento

In MIPS ci sono 5 modalità di indirizzamento:

- Immediato (quello usato dalle istruzioni di tipo I)
- A registro (quello usato dalle istruzioni di tipo R)
- Con base e offset (quello usato da **lw/sw**)
- Relativo al program counter (quello usato da **beq**)
- Pseudo diretto (quello usato da **jr**)

Etichette

Le etichette vengono usate per dare nomi simbolici a delle celle di memoria. Sarà compito dell'assemblatore tradurre le etichette in indirizzi di memoria. Sintassi:

```
etichetta:
    add $1, $2, $3 # anche direttiva
```

Traduzione da C a MIPS


Per tradurre da un linguaggio sorgente a un linguaggio macchina, bisogna definire un modello di architettura runtime. Alcune delle convenzioni di questo modello sono:

- collocazione e ingombro di tipi di variabili
- destinazione di uso dei registri

Modello di memoria

La memoria di un programma è divisa in vari segmenti:

- `text (.text)`: codice del programma (dichiarato dal programma)
- `data (.data)`: dati statici e dinamici (dichiarato del programma)
- `stack`: la stack del processo (allocato dal sistema operativo)



Gli indirizzi di impianto dei segmenti sono indirizzi virtuali, non fisici.

Programmi molto grandi e sofisticati possono avere due o più segmenti dati o testo, segmenti di dati condivisi, segmenti di libreria dinamica e altro.

Syscall

La `syscall` è un'istruzione che passa il controllo al kernel. Il kernel offre vari servizi, ognuno indentificato da un codice.

Il codice, prima, viene salvato dal chiamante nel registro `$v0`, seguito dagli argomenti in `$a*` o `$f12`. Viene poi chiamata l'istruzione `syscall`.

Se una `syscall` ritorna un valore, esso viene salvato nel registro `$v0`, anche `$f0` se è più grande di 32 bit.

Dimensioni delle variabili

tipo	dimensione (B)
<code>char</code>	1
<code>short</code>	2
<code>int</code>	4
<code>void*</code>	4

Per dichiarare un array allochiamo semplicemente `n*dimensione` byte. Per accederci, usiamo l'aritmetica dei puntatori (come si fa anche in C): `base + (dimensione * n)`.

Una sintassi alternativa di `.word` è: `.word n, m, ...`. Essa equivale all'inizializzazione diretta di un array (come in C)

Per dichiarare una `struct`, basta semplicemente allocare una dimensione di pari alla dimensione totale della `struct`. Per accedere ai vari elementi, semplicemente ci accede come ad un array, tenendo conto dell'ordine degli elementi.

Classi di variabili

In C abbiamo diversi tipi di variabili: globali, locali, parametri e allocate dinamicamente.

Variabili globali

Le variabili globali sono allocate in `.data` a partire da `0x10000000`. Per indirizzarla usiamo un'etichetta che gli assegniamo.

Per puntare al segmento dati statici usiamo il registro `$gp`, inizializzato all'indirizzo `0x10008000`

Variabili locali

Per le variabili locali posso usare i registri `$s*`. Se, però, ho bisogno di usare l'indirizzo di una variabile locale, essa andrà salvata sulla stack.

Parametri

I primi quattro parametri vengono passati tramite i registri `$a*`. Se la funzione ha più di 4 parametri essi vengono salvati sulla stack.

Nota bene: per array e struct viene passato l'indirizzo!

Il chiamante, prima della chiamata, salva in memoria i registri che vuole mantenere inalterati durante la chiamata.

Per i valori in uscita si usa il registro `$v0`. Se la return è più lunga di 32 bit si usa anche il registro `$v1`.

Variabili dinamiche

Come anche in C, bisogna ricorrere a una funzione che ci allochi memoria sulla heap. Viene utilizzata la syscall `sbrk` (codice 9 su SPIM) passando in entrata il numero di byte da allocare. L'indirizzo dello spazio di memoria allocato è ritornato in `$v0`.

Funzioni

La chiamata a funzione, in linguaggi come il C, ha come effetto la creazione di un record di attivazione sulla stack. Il record di attivazione contiene:

- i parametri formali e i loro valori
- l'indirizzo di ritorno al chiamante
- le informazioni per gestire lo spazio allocato per il record
- le variabili locali
- il valore restituito

Il chiamante esegue le seguenti operazioni preliminari:

1. Predispone i parametri in ingresso negli opportuni registri
2. Salva sulla stack il valore di registri che vuole mantenere
3. Trasferisce il controllo alla procedura tramite `jal`

Il chiamato esegue le seguenti operazioni:

1. Alloca lo spazio di memoria necessario alla memorizzazione dei dati e alla sua esecuzione
2. Salva alcuni registri sulla stack
3. Eseguire le sue funzioni
4. Memorizzare il risultato nell'apposito registro
5. Ripristina i registri salvati sulla stack
6. Ritornare il controllo al chiamante tramite `jr`

Salvataggio dei registri

Vengono salvati sullo stack solo un particolare gruppo di registri. I registri che vengono preservati dal chiamato sono: `$s*`, `$fp`, `$ra`.

I registri che il chiamante può salvare, invece, sono: `$t*`, `$a*` e `$v*`.

Entrambe le parti devono salvare i registri solo se verranno modificati.

Minimo salvataggio dei registri

- Il chiamato non deve salvare nulla se:
 - Non chiama nessun'altra funzione
 - scrive solo in registri temporanei, per parametri, per risultati o non indirizzabili
- La funzione chiamante non deve salvare nulla se:
 - non vuole salvare il contenuto dei suoi registri temporanei, parametro e risultato

Gestione dello stack

Lo stack cresce dall'altro verso il basso. Lo stack pointer contiene l'indirizzo della cima della stack. Quindi ogni volta che dobbiamo spingere qualcosa sulla stack dobbiamo decrementare lo stack pointer e ogni volta che dobbiamo rimuovere qualcosa dobbiamo incrementarlo.

PUSH:

```
addi $sp, $sp, -4
sw $reg, 0($sp)
```

POP:

```
lw $reg, 0($sp)
addi $sp, $sp, 4
```

Nello stack sono salvati i record di attivazione (frame). Lo spazio sulla stack viene allocato dal programmatore in una sola volta all'inizio della procedura. Lo stesso vale per la deallocazione.

Stack frame

Lo stack frame è allocato dal chiamato e ha la seguente forma:

```
-----
Registri salvati
dal chiamante
-----
Parametri (5, 6...)
----- <- $fp

Registri salvati

-----

Variabili locali

----- <- $sp
```

Il registro `$fp` punta alla prima parola del frame, mentre `$sp` punta all'ultima parola del frame. L'utilizzo del frame pointer è opzionale.

Il layout dei registri salvati è il seguente:

```
...
-----
Vecchio $fp
-----
Vecchio $ra
-----

Vecchi $s0 - $s7
-----
....
```

La generalizzazione dello stack frame è l'area di attivazione e comprende anche i registri salvati dal chiamante.

Funzioni foglia

Si dice funzione foglia una funzione che non ha annidate al suo interno altre chiamate a procedure. La peculiarità di questo tipo di funzioni è che non deve salvare il valore di `$ra`.

Valutazioni espressioni algebriche

Adotteremo la regola più semplice senza ottimizzare. Basta seguire un semplice procedimento:

1. Completa l'espressione associando a sinistra

2. Finché non hai finito valuta il primo operatore valutabile da sinistra

Un operatore viene considerato valutabile se da entrambi i lati sono presenti solo costanti o risultati di sotto-espressioni già calcolate.

Flusso di compilazione e assemblaggio

Un programma C passa attraverso diverse fasi prima di essere eseguibile: prima viene compilato in linguaggio assembler, poi viene assemblato da un assembler in linguaggio macchina e poi i riferimenti ad altre funzioni o variabili vengono riempiti (collegato) per poi essere eseguibile.

Ciò che ci interesserà di più è il processo di assemblaggio.

L'assemblaggio

L'assembler legge, riga per riga, le istruzioni simboliche e poi le traduce in formato macchina:

- Le pseudo istruzioni vengono espanse
- Le istruzioni vengono tradotte nel loro corrispettivo binario
- I riferimenti ai registri vengono tradotti nei loro “numeri” di registro
- I riferimenti simbolici vengono risolti

Ogni segmento è assemblato in termini di memoria virtuale rilocabili.

Il risultato dell'assemblaggio è la generazione dei file oggetto.

Tabella dei simboli

Il primo passo svolto dall'assemblatore è la costruzione della tabella dei simboli, ossia una corrispondenza tra le varie etichette e i rispettivi indirizzi di memoria. Le etichette definite come globali (`.globl`) vengono rese disponibili anche ad altri oggetti.

I valori degli indirizzi usati non sono assoluti, ma sono rilocabili ossia relativi alla posizione del segmento a cui appartengono.

Assemblaggio e tabella di rilocalizzazione

Usando la tabella dei simboli e la tabella di rilocalizzazione, l'assemblatore assembla le varie istruzioni

Alcune istruzioni vengono assemblate in modo incompleto e vanno processate anche dal linker. Una istruzione viene tradotta parzialmente se:

- il riferimento simbolico al suo interno è relativo al segmento `.data`
- il riferimento è relativo a simboli non presenti nella tabella dei simboli (il simbolo è posto a 0 per convenzione)
- è un istruzione di salto di tipo J (usa indirizzi assoluti): il simbolo è posto a 0 per convenzione

In corrispondenza a ogni elemento tradotto incompletamente è creato un elemento nella tabella di rilocalizzazione della forma:

<indirizzo rilocabile dell'istruzione, OPCODE, simbolo da risolvere>

L'indirizzo del simbolo in una branch, se locale, può essere risolto subito con questa formula: $(\text{DEST_REL_ADDR} - (\text{SOURCE_REL_ADDR} + 4))/4$

Il formato oggetto

Il formato di un oggetto è il seguente:

object file	text	data	relocation	symbol	debug
header	segment	segment	information	table	info

- L'intestazione: descrive le dimensioni di testo e dati
- Il segmento di testo: contiene le istruzioni eseguibili; esse potrebbero essere non complete a causa di riferimenti non risolti
- Il segmento dati: Contiene una rappresentazione binaria dei dati definiti nella sorgente; essi potrebbero non essere completi a causa di riferimenti non risolti
- Le informazioni di rilocalizzazione: identificano le istruzioni che dipendono da indirizzi assoluti
- La tabella dei simboli: associa un indirizzo alle etichette globali
- Le informazioni di debug

Indirizzamento di dati statici

Poiché il segmento dati inizia all'indirizzo 0x10000000, le istruzioni di load non possono far riferimento direttamente ai dati. Per evitare ogni volta di espandere le load in due istruzioni, viene usato il `$gp` come riferimento per lo spiazamento (con segno) di 16 bit delle istruzioni di load e store.

L'utilizzo del global pointer permette di accedere ai primi 64 kB del segmento di dati statici.

Simboli rilocabili, locali ed esterni

Gli indirizzi all'interno del modulo possono variare se i vari segmenti dell'oggetto sono rilocati. Di conseguenza tutte le etichette che corrispondono ad indirizzi assoluti possono puntare ad indirizzi diversi.

Un simbolo può essere locale (definito nel modulo) o esterno (definito in un altro modulo).

L'assemblatore non può tradurre completamente istruzioni se:

- fa riferimento ad un simbolo esterno (risolto dal linker)
- fa riferimento ad un simbolo rilocabile (risolto dal linker)
 - un'eccezione sono le istruzioni di branch in quanto compiono un salto relativo al PC e la distanza relativa delle istruzioni non viene modificata

Il linker

Il compito del linker è quello di mettere insieme i diversi moduli di un programma.

Il linker “collega” i vari oggetti risolvendo i simboli esterni e crea un vero e proprio eseguibile.

Il linker crea un unico programma binario eseguibile con un solo spazione di indirizzamento per tutto il programma.

Il linker prima:

- Determina la posizione in memoria delle sezioni di codice e dati dei diversi moduli
 - I moduli solo caricati in memoria sequenzialmente rispettando la struttura generale della memoria
- Crea la tabella dei simboli globale
 - Essa consiste nell'unione di tutte le tabelle dei simboli di tutti i moduli che devono essere collegati, modificate in base all'indirizzo di base del modulo di appartenenza di ciascun simbolo
- Corregge in tutti i moduli i riferimenti ad indirizzi simbolici

Regole di correzione dei riferimenti nei moduli

Siano:

- ISTR un'istruzione riferita dalla tabella di rilocazione di un modulo M, con simbolo S e indirizzo IND
- IADDR l'indirizzo di una istruzione ISTR riferita dalla tabella di rilocazione di un modulo M con simbolo S
- VS il valore di S nella tabella globale dei simboli
- GP il valore del global pointer

Regole da applicare in base al tipo di istruzioni:

- ISTR è in formato J: inserire $VS/4$ nell'istruzione
- ISTR è di salto in formato I: inserire $(VS - (IADDR + 4)) / 4$
- ISTR è aritmetico/logica in formato I: inserire i 16 bit meno significativi di VS (VS_Low)
- ISTR è di tipo load o store: inserire $VS-GP$
- ISTR è l'istruzione lui: inserire i 16 bit più significativi di VS (VS_High)

Caricamento ed esecuzione del programma

Nei sistemi UNIX, il kernel carica il programma in memoria e ne lancia l'esecuzione. Le operazioni eseguite sono:

1. Legge l'intestazione dell'eseguibile per determinare le dimensioni dei vari segmenti
2. Crea un nuovo spazio di indirizzamento per il programma abbastanza grande per contenere i vari segmenti del programma (inclusa la stack)
3. Copia le istruzioni e i dati del file eseguibile in memoria all'interno dello spazio appena allocato
4. Copia nello stack gli argomenti passati al programma
5. Inizializza i registri dell'architettura (in generale tutti azzerati tranne per lo stack pointer a cui viene assegnato il nuovo indirizzo della stack)

6. Salta a una procedura di avvio che copia i gli argomenti del programma dallo stack ai registri, per poi chiamare la procedura `main` del programma.
7. Quando la procedura `main` termina, la procedura di avvio conclude il programma attraverso la syscall `exit`

Librerie dinamiche

Alcune volte, per ridurre le dimensioni degli eseguibili, alcune librerie vengono collegate solo a runtime. Il linker dinamico esegue la procedura di caricamento in memoria alla prima chiamata di un determinato simbolo.

Livello logico-digitale

I segnali

I segnali che utilizzeremo saranno segnali discreti, adatti a rappresentare i numeri binari. Essi sono derivati da segnali elettrici continui. La grandezza che varierà sarà la tensione elettrica: essa oscillerà tra un minimo ed un massimo che rappresentano rispettivamente 0 e 1.

Ci sono due classi di dispositivi di elaborazione:

- reti combinatorie: reti senza retroazioni: il risultato dipende solo dagli ingressi
- reti sequenziali: reti con retroazioni: il risultato dipende sia dagli ingressi che dalla sequenza di segnali precedenti (stato del circuito)

I circuiti sequenziali

Un circuito sequenziale possiede uno stato che ne influenza il comportamento

Lo stato di un circuito sequenziale rappresenta una sorta di descrizione della storia passata del circuito stesso. L'elemento funzionale elementare per la realizzazione di circuiti sequenziali è il bistabile, che è in grado di memorizzare un bit di informazione.

I circuiti sequenziali sono formati da:

- bistabili: memorizzano valori di singoli bit
- porte logiche organizzate in reti combinatorie: elaborano le informazioni

Algebra di commutazione

Deriva dall'algebra di Boole e consente di descrivere matematicamente i circuiti digitali. Definisce espressioni logiche che descrivono il comportamento del circuito da realizzare nella forma $U = f(I)$. A partire da queste espressioni è possibile derivare una rappresentazione circuitale.

Operatori

Chiameremo variabile di commutazione, o variabile logica, il singolo bit di informazione rappresentata e elaborata.

- Negazione: $\neg A$ vale 0 se A è 1 e viceversa
- Somma logica: equivale a OR
- Prodotto logico: equivale a AND

Proprietà

Legge	AND	OR
Identità	$1 \wedge A = A$	$0 \vee A = A$
Elemento nullo	$0 \wedge A = 0$	$1 \vee A = 1$
Idempotenza	$A \wedge A = A$	$A \vee A = A$
Inverso	$A \wedge \neg A = 0$	$A \vee \neg A = 1$
Commutativa	$A \wedge B = B \wedge A$	$A \vee B = B \vee A$
Associativa	$(A \wedge B) \wedge C = A \wedge (B \wedge C)$	$(A \vee B) \vee C = A \vee (B \vee C)$
Distributiva	$A \wedge (B \vee C) = (A \wedge B) \vee (A \wedge C)$	$A \vee (B \wedge C) = (A \vee B) \wedge (A \vee C)$
Assorbimento	$A \wedge (A \vee B) = A$	$A \vee (A \wedge B) = A$
De Morgan	$\neg(A \wedge B) = \neg A \vee \neg B$	$\neg(A \vee B) = \neg A \wedge \neg B$

Funzione combinatoria

Una funzione combinatoria corrisponde ad una espressione booleana. Essa si comporta esattamente come una normale funzione.

Porte logiche

I circuiti digitali sono formati da componenti digitali elementari, chiamate porte logiche, ossia circuiti minimi per l'elaborazione di segnali binari e corrispondono agli operatori elementari dell'algebra di commutazione. L'insieme NOT, AND e OR è detto insieme di operatori funzionalmente completo, ossia un insieme con il quale è possibile costruire qualsiasi calcolatore.




Figure 1: Porte logiche fondamentali

Oltre alle porte logiche fondamentali si definiscono altre 2 porte anch'esse funzionalmente complete: NAND ($\neg(AB)$) e NOR ($\neg(A+B)$). Con NAND e NOR si possono costruire tutti e tre gli operatori fondamentali.




Figure 2: Porte logiche negate

Definiamo ancora altre 2 porte logiche: XOR ($\neg AB + A\neg B$ o OR esclusivo) e XNOR ($\neg(\neg AB + A\neg B)$ o NOR esclusivo). Essi sono utilizzati per contare il numero di bit: XOR ci dice se c'è un numero dispari di 1, mentre XNOR se c'è un numero pari.




Figure 3: Porte logiche esclusive

Esistono porte con più di 2 ingressi. Esse però sono realizzate con delle porte a 2 ingressi (ad esempio una porta a 3 ingressi viene realizzata con 2 porte a 2 ingressi). Nel conteggio delle porte logiche utilizzate bisogna usare come unità di misura le porte a 2 ingressi.

Le porte logiche sono costruite tramite i transistor. Il transistor funziona come un interruttore: ha uno stato di aperto e uno chiuso.

Costo e velocità delle porte

Il costo di realizzazione equivale al numero di transistor necessari per realizzare una porta. Esso dipende dalla tecnologia utilizzata, dalla funzione e dal numero di ingressi.

Ogni porta ha anche una velocità di commutazione. Anch'essa come il costo dipende da tecnologia, funzione e numero di ingressi.

Il costo delle porte e la velocità permettono di calcolare il costo della rete logica e il ritardo di propagazione associato alla rete.

Nel conteggio di solito non includiamo le porte NOT in quanto costituite solo da 1 transistor.

Analisi e sintesi di reti combinatorie

A ogni funzione combinatoria si può sempre associare un circuito digitale formato da porte logiche chiamato rete combinatoria. Gli ingressi della rete saranno le variabili della funzione e le uscite il valore della funzione. Considereremo sempre solo 1 uscita.

Una funzione combinatoria può ammettere più reti combinatorie che differiscono per il numero di porte logiche.

L'operazione di trovare la funzione combinatoria data una tabella di verità viene detta sintesi. L'inverso (trovare la tabella di verità di una rete o funzione) è detta analisi.

Sintesi

La sintesi di una rete combinatoria è un problema Np completo, ossia esiste un algoritmo che risolverà sempre il problema, anche se non nel modo più ottimale.

Data una funzione booleana, la soluzione iniziale al problema consiste nel ricorso alle forme canoniche:

- forma somma di prodotti (SoP o prima forma canonica)
- forma prodotto di somme (PoS o seconda forma canonica)

Data una una funzione booleana esistono una e una sola espressione per ciascuna delle forme canoniche.

Le forme canoniche non sono una forma ottimale. E', quindi, necessaria una ottimizzazione utilizzando i teoremi dell'algebra combinatoria visti sopra

Sintesi in prima forma canonica

La funzione F può essere specificata come:

- la somma di tutti i termini prodotto delle variabili di ingresso corrispondenti agli 1 della funzione
- Ogni termine prodotto (o mintermine) è costituito dal prodotto logico delle variabili di ingresso prese in forma naturale (se valgono 1) o in forma complementata (se valgono 0)

Sintesi in seconda forma canonica

La funzione F può essere specificata come:

- il prodotto di tutti i termini somma delle variabili di ingresso corrispondenti agli 0 della funzione
- il termine somma (o maxtermine) è costituito dalla somma logica delle variabili di ingresso prese in forma naturale se valgono 0 o in forma complementata se valgono 1

I blocchi funzionali combinatori

Esiste una libreria di blocchi funzionali predefiniti di tipo combinatorio che contiene i blocchi per tutte le funzioni combinatorie di base:

- Multiplexer/demultiplexer
- Decoder
- Confrontatore
- Shifter combinatorio
- Half/full adder
- Addizionatore a n bit
- ALU or, not, e somma

Multiplexer

Ha $n \geq 1$ ingressi di selezione, $2^n > 2$ ingressi dati e un'uscita. Gli ingressi dati sono numerati a partire da 0. Sugli ingressi di selezione è presente il numero binario k e il k-esimo ingresso dati viene inviato in uscita.

Demultiplexer

Ha $n \geq 1$ ingressi di selezione, 1 ingresso dati e $2^n > 2$ uscite. Ha la funzione opposta del multiplexer.

Decoder

Ha $n \geq 1$ ingressi e $2^n > 2$ uscite. Le uscite sono numerate a partire da 0. Se sugli ingressi è presente il numero binario k, la k-esima uscita assume il valore 1 e le restanti uscite assumono il valore 0.




Figure 4: Multiplexer




Figure 5: Demultiplexer

Comparatore

Ha due gruppi A e B di ingressi da $n \geq 1$ bit ciascuno e tre uscite: minoranza, uguaglianza e maggioranza. Il blocco confronta i due numeri binari A e B presenti sui due ingressi e attiva l'uscita corrispondente all'esito del confronto.

Shifter combinatorio

Ha $n \geq 1$ ingressi, 1 ingresso per il bit aggiunto a dx, 1 ingresso per il bit aggiunto a sx, 1 ingresso di controllo che comanda lo scorrimento, $n \geq 1$ uscite. Sull'uscita vengono attivati i bit corrispondenti al numero shiftato a destra o sinistra.

Viene implementato con multiplexer in serie.

Half adder

Ha come input 2 bit e come output la somma dei due bit e il riporto. Viene implementato con un AND e un XOR.




Figure 6: Half Adder

Full adder

Ha come input 2 bit e il CarryIn e come output la somma e il riporto. Esegue la somma dei due bit tenendo conto del riporto in entrata.

Addizionatore a k bit in binario naturale intero




Figure 7: Full Adder

Ha come input 2 numeri binari e come output la somma e il riporto. He formato da una cascata di Half Adder e Full Adder. Questa struttura è molto lenta, soprattutto per numeri con grande numero di bit. Ci sono addizionatori più veloci basati sul carry look-ahead, un blocco funzionali che cerca di prevedere il valore del carry per velocizzare il processo.

Il sottrattore funziona alla stessa maniera e viene sintetizzato analogamente.

Unità aritmetico logica

Ha 2 ingressi da n bit, un ingresso per i comandi, un'uscita di esito e il risultato dell'operazione. L'esito viene usato per segnalare l'esito dei confronti o informazioni addizionali per date operazioni matematiche.

Bistabili

Esistono due famiglie di bistabili:

- Asincroni: privi di un segnale di sincronizzazione e modificano lo stato rispondendo direttamente a eventi sugli ingressi
- Sincroni: sensibili ad un segnale di controllo e la transizione da uno stato all'altro può avvenire solo in corrispondenza di eventi del segnale di controllo
 - bistabili sincroni controllati (gated latch)
 - flip-flop master-slave
 - flip-flop edge-triggered

Bistabili SR asincroni

Ha 2 ingressi, S (set) e R (Reset), e 2 uscite Q e !Q:

- $Q = 1$: stato di set
- $Q = 0$: stato di reset

L'uscita Q rappresenta, quindi, lo stato memorizzato.

Studiando il circuito si nota che ci sono solo due stati stabili (bistabile):

- $S = R = 0, Q = 1$

- $S = R = 0, Q = 0$

Se viene passato $R = 1$ allora $Q = 0$ qualunque sia il vecchio valore. Se viene passato $S = 1$ allora $Q = 1$ qualunque sia il vecchio valore. Se sia S che R sono 1, si avrà uno stato indefinito in cui sia Q che $!Q$ sono nulli.




Figure 8: Bistabile SR asincrono

Segnale di sincronizzazione

E' un segnale binario con andamento periodico nel tempo. Esso è una successione di impulsi consecutivi a distanza costante. Il periodo di clock è il tempo dall'inizio del livello inferiore fino alla fine del livello superiore. Un ciclo di clock contiene 3 eventi: livello basso, fronte di salita, fronte di discesa.

Bistabili sincroni

I fattori che differenziano i bistabili riguardano due aspetti:

- la relazione ingresso-stato: definisce quando gli ingressi vengono modificati
 - temporizzazione basata sul livello: il valore viene modificato durante tutta la permanenza su un livello
 - temporizzazione basata sul fronte: il valore viene modificato solo durante il fronte
- relazione stato-uscita: definisce quando le uscite vengono modificate
 - commutazione basata sul livello: le uscite vengono aggiornate durante tutta la permanenza su un livello (latch)
 - commutazione basata sul fronte: le uscite vengono aggiornate solo durante il fronte

	Livello	Fronte
Fronte	N.A.	Flip-flop edge-triggered
Livello	Latch con Enable	Flip-flop master-slave

Affinché i bistabili sincroni funzionino, è necessario che il tempo di clock sia lungo tanto quanto il più lungo cammino nella logica combinatoria associata. Se ciò avviene, possiamo ottenere lettura e scrittura all'interno di un singolo stato di clock.

Bistabile SR sincrono (SR-latch)

Il bistabile SR sincrono è molto simile al bistabile SR asincrono. Esso ha in più l'entrata per il segnale di sincronizzazione. Inoltre se il clock vale 0, i segnali non vengono modificati, se è 1 si comporta come un bistabile SR asincrono.

Bistabile D sincrono (D-latch)

Ha 1 ingresso D (dati), 1 ingresso di clock e le due uscite Q e $!Q$ come negli altri bistabili. Se il clock vale 0, l'ingresso D non è efficace, se è 1 l'ingresso D è efficace e il bistabile memorizza il valore logico in D .

Se il clock è 1, il bistabile si dice trasparente: le uscite sono sempre pari alle entrate, come se non ci fosse. Per evitare il fenomeno di trasparenza, dobbiamo usare i flip-flop.

Flip-flop D master-salve

Sono realizzati tramite una coppia di bistabili sincroni D in cascata con clock invertiti. L'insieme dei due permette di eliminare il fenomeno della trasparenza.




Figure 9: Bistabile SR sincrono




Figure 10: Bistabile D sincrono




Figure 11: Flip-flop D master-slave

Flip-flop D edge-triggered

Sono meno costosi rispetto ai flip-flop master-slave. Sono realizzati con 3 SR latch asincroni e 1 porta OR. Nelle implementazioni reali sono più utilizzati della controparte master-slave.




Figure 12: Flip-flop D edge-triggered

Blocchi funzionali sequenziale

I tipi principali sono:

- Registro parallelo
- Registro a scorrimento
- Banco di registri
- Memoria

Il registro parallelo

E' un vettore di $n \geq 1$ flip-flop di tipo D. Ha $n \geq 1$ ingressi e uscite e l'ingresso per il clock.

A ogni ciclo di clock, il registro legge e memorizza nel suo stato la parola di n bit presenti in ingresso e lo presenta sui n bit di uscita il prossimo ciclo.

Il registro parallelo è formato da n flip-flop sincroni tutti in parallelo. Il clock viene condiviso tra tutti i bistabili. Se si usano dei bistabili sincroni su livello, o asincroni, il registro sarebbe anch'esso trasparente.




Figure 13: Registro parallelo (4 bit)

Il registro di parallelo con comando di caricamento funziona allo stesso modo del registro parallelo, ma ha un ingresso in più: il comando L. Quando il comando L è attivo, viene aggiornato lo stato; quando il comando L non è attivo lo stato viene mantenuto.

Il registro parallelo con comando è realizzato in modo simile al registro parallelo, solo con un multiplexer con comando L in entrata a ogni bistabile.




Figure 14: Registro parallelo con comando (2 bit)

Esistono altre varianti di registri paralleli con diversi comandi.

Registro a scorrimento

E' simile al registro parallelo, ma prende i bit in ingresso in modo seriale invece che in parallelo. Avrà quindi un solo ingresso S, un ingresso di clock e $n \geq 1$ uscite.

A ogni ciclo di clock fa scorrere di un bit verso destra la parola memorizzata aggiungendo a sinistra il bit presente sull'ingresso seriale.

Viene realizzato usando flip-flop in cascata. L'uso di bistabili trasparenti causerebbe un comportamento errato.




Figure 15: Registro a scorrimento (4 bit)

Esistono diverse varianti di registro a scorrimento: a destra, a sinistra o universale (scelta con comando). Possiamo anche avere un registro che combina le funzionalità del parallelo e dello scorrimento in base al comando. Possiamo anche avere ingressi seriali, uscite seriali o una combinazione di parallelo e seriale.

Banchi di registri e memoria

Circuito di pilotaggio

Per pilotare le uscite dei vari componenti di memoria deve essere regolata in modo da garantire un comportamento consistente. Per fare ciò sono necessari dei circuiti di pilotaggio delle uscite. Per fare ciò si usa il buffer tri-state.

Il buffer tri-state ha 3 posizioni:

- uno stato di bassa impedenza consente il passaggio di entrambi i livelli di tensione
- uno stato di alta impedenza isola elettricamente l'uscita

Il comportamento viene regolato da un segnale di controllo (Output Enable).

Banchi di registri

I banchi di registri sono strutture tipo vettore dove ogni elemento è un registro parallelo.

Si consideri un banco 8x16 (8 registri da 16 bit). Ogni registro è identificato da un indirizzo. Serviranno quindi 3 bit per indirizzare i vari registri. Le operazioni eseguibili sul banco sono lettura e scrittura.

Possiamo quindi disegnare il banco di registri 8x16 come un blocco sequenziale con:

- 3 ingressi indirizzo
- 16 uscite e ingressi dati
- 1 ingresso di comando (lettura o scrittura)
- 1 ingresso di abilitazione al banco
- 1 ingresso di controllo per la gestione delle uscite tri-state
- il segnale di clock

I banchi, ovviamente, esistono in diverse dimensioni. I banchi più sofisticati possono avere più porte di accesso distinte, in lettura/scrittura o solo per una delle due, per poter operare in parallelo su più registri.

Memoria

La memoria è un tipo di tipo sequenziale complesso. Ha anch'essa una struttura a vettore i cui elementi sono le parole di memoria. Un componente integrato (chip) è caratterizzato da:

- capacità misurata in numero totale di bit memorizzabili
- le funzioni (lettura/scrittura)
- il numero di porte d'accesso
- il tempo utilizzato per l'accesso alla memoria

Solitamente il contenuto della memoria viene letto/scritto una parola per volta in un ciclo di clock. Per accedere alla memoria si usa la porta d'accesso alla memoria.

La porta di accesso è formata da:

- Gli ingressi di indirizzo: codificano l'indirizzo della cella su cui si deve operare
- Le uscite/ingresso di dato: servono per leggere/scrivere una parola
- il comando di lettura/scrittura
- il comando di abilitazione del componente
- il comando di abilitazione delle uscite dati

Le strutture interne della memoria sono diverse. Il modo più semplice (non adatto a grandi capacità) è quello di creare una matrice di bistabili dove le righe sono le parole e le colonne i bit della parola. Le memorie ad alta capacità sono solitamente disposti a matrice bidimensionale per ridurre i collegamenti interni. In questo caso saranno necessari altri due comandi: RAS e CAS (Row Address Select e Column Address Select).

I banchi di memoria sono l'aggregazione di più componenti di memoria per ottenere memoria di capacità più elevata. I banchi di memoria hanno struttura a matrice di chip:

- Per aumentare la lunghezza della parola si compone una colonna di chip di memoria da usare in parallelo
- Per aumentare il numero di parallelo si compone una riga di chip di memoria da usare in esclusione

Tecnologie di memoria

SRAM (Static RAM)

E' una memoria realizzata con bistabili. Perciò ha una capacità medio-piccola ed è volatile. Ha un tempo di accesso molto veloce ma occupa tanto spazio (6 transistor per bit). Viene usata come cache dei professori

DRAM (Dynamic RAM)

E' una memoria che usa circa 1 transistor per bit (fenomeno di accumulo di carica sul transistor). Ha una alta densità e quindi può essere usata per creare memorie più grandi. Il tempo di accesso è medio ed anch'essa è volatile. Viene usata per la memoria centrale.

ROM

Memoria a sola lettura realizzata come matrice di transistor. Ha una capacità grande e un tempo di accesso medio. Essa è persistente. Viene usata per memorizzare programmi permanenti non modificabili.

Per memoria ROM si intendono anche i sistemi ottici (CD-ROM ecc.). Noi considereremo memoria ROM solo quella a stato solido basata su transistor.

PROM, EPROM, EEPROM

Capacità e tempo simili alla ROM. Anch'esse sono di sola lettura e persistenti. Possono essere riprogrammate tramite un apposito programmatore:

- PROM: programmabile solo 1 volta
- EPROM: cancellabile con raggi UV e riscrivibile un numero limitato di volte
- EEPROM: cancellabile elettricamente e scrittura di 1 byte alla volta

Le memorie cancellabili sono anche dette “read-mostly”. Si usano principalmente per sistemi embedded e prototipi.

Memoria FLASH

Capacità e tempo poco inferiori alla DRAM. Funziona in lettura e scrittura (scrittura a blocchi di byte) ed è persistente. Viene usata per dati multimediali o programmi fissi ma periodicamente aggiornabili.

Il processore

Nella progettazione del processore considereremo un set di istruzioni ridotto per semplificarci le cose. Useremo le solite ipotesi dell'architettura LOAD-STORE.

Prima progetteremo il processore per l'esecuzione di una istruzione alla volta, poi vedremo l'uso dell'architettura a pipeline per poter eseguire più istruzioni alla volta.

Esecuzione di una istruzione

Esecuzione di istruzioni aritmetico logiche

Viene eseguita in 4 passi:

- Prelievo istruzione dalla memoria e incremento del program counter
- Lettura dei due registri sorgente dal banco di registri
- Operazione dell'ALU sui dati letti dal banco di registri utilizzando il codice operativo e il campo **function**
- Scrittura del risultato dell'ALU nel banco registri utilizzando il registro di destinazione

Per le istruzioni aritmetiche immediate i passaggi sono più o meno gli stessi. Cambia solamente il fatto che viene letto solo 1 dei due registri e si carica in 1 dei registri di ingresso all'ALU il valore immediato

Esecuzione di istruzioni di load e store

Le istruzioni di **load** richiedono 5 passaggi:

- Prelievo istruzione dalla memoria e incremento del program counter
- Lettura del registro base dal banco dei registri
- Operazione dell'ALU per calcolare la somma del valore letto dal registro base e dei 16 bit meno significativi dell'istruzione estesi in segno
- Prelievo del dato nella memoria dati utilizzando come indirizzo di lettura il risultato dell'ALU
- Scrittura del dato proveniente dalla memoria nel registro di destinazione

La **store** è simile, ma salta un passaggio di lettura da memoria:

- Prelievo istruzione dalla memoria e incremento del program counter
- Lettura del registro base e del registro sorgente dal banco di registri
- Operazione dell'ALU per calcolare la somma del valore letto dal registro base e dei 16 bit meno significativi dell'istruzione estesi in segno
- Scrittura del dato proveniente dal registro sorgente alla memoria

Istruzione di salto condizionato

Richiede 5 passi:

- Prelievo istruzione dalla memoria e incremento del program counter
- Lettura dei registri sorgente dal banco dei registri
- Operazione dell'ALU per effettuare la sottrazione tra i valori letti dal banco di registri. Il valore viene sommato ai 14 bit meno significativi dell'istruzione estesi di segno. Il risultato è l'indirizzo di destinazione del salto.
- L'uscita **zero** dell'ALU viene usata per decidere quale valore debba essere memorizzato nel program counter ($\$pc + 4$ o $\$pc + 4 + \text{offset}$)

Istruzioni di salto incondizionato

Richiedono tecnicamente un solo passaggio, quello di fetch. Lo shift e la somma al program counter viene eseguito da un circuito combinatorio dedicato.

Realizzazione del processore a ciclo singolo

Per garantire il corretto funzionamento della logica combinatoria, ogni tipo di istruzione non può condividere tutte le componenti con gli altri. Alcuni componenti dovranno, quindi, essere duplicati e l'output va filtrato con l'uso di un multiplexer e di un segnale di controllo. Servono anche dei segnali di controllo per regolare ALU, lettura e scrittura:

Nome	Se 1	Se 0
RegDst	Il registro di scrittura proviene da \$rt	Il registro di scrittura proviene da \$rd
RegWrite	Nulla	Il dato viene scritto nel registro di scrittura
ALUSrc	Il secondo operando dell'ALU proviene dal secondo dato letto	Il secondo operando dell'ALU proviene dall'estensione di segno del secondo dato letto
ALUOp	Controlla l'operazione eseguita dalla ALU	Controlla l'operazione eseguita dalla ALU
PCSrc	Nel PC viene scritta l'uscita di \$pc + 4	Nel PC viene scritta l'uscita del sommatore che calcola l'indirizzo di salto
MemRead	Nulla	Il dato della memoria nella posizione puntata dall'indirizzo viene considerato dato letto
MemWrite	Nulla	Il dato della memoria nella posizione puntata dall'indirizzo viene considerato dato letto
MemToReg	Il dato inviato per la scrittura proviene dalla ALU	Il dato inviato per la scrittura proviene dalla memoria dati

E' ovvio, quindi, che serve un'unità di controllo che prende in input il codice operativo dell'istruzione e regola il valore delle varie linee di controllo. Conoscendo i vari codici operativi, è possibile costruire una tabella di verità e costruire il circuito combinatorio equivalente.

CPU a singolo ciclo e multiciclo

Ogni istruzione verrà eseguita in un ciclo di clock. Questo ci limita in velocità: siamo limitati dall'istruzione più lenta. L'implementazione di un ciclo variabile sarebbe molto più complessa per poco guadagno. Un'altra soluzione è quella di distribuire un'istruzione su più cicli, creando una CPU multiciclo.

In una CPU multiciclo:

- Ogni fase d'esecuzione di un'istruzione richiede 1 ciclo di clock
- Un'unità funzionale può essere usata più di una volta per istruzione in cicli di clock diversi, consentendo la condivisione di elementi funzionali
- E' necessario introdurre dei registri interni addizionali per memorizzare i valori da usare nei cicli successivi

Avremo, quindi, una distribuzione su un massimo di 5 cicli di clock con ciascun clock di durata inferiore. Ogni fase impiega lo stesso tempo, anche se fosse più veloce poiché dobbiamo accomodare la fase più lenta. In più, ogni singola istruzione dovrà passare attraverso tutti e 5 i cicli. Ciò rende il tempo di esecuzione più lungo rispetto al singolo ciclo, andando contro il nostro obiettivo di migliorare le prestazioni.

Pipeline

L'idea dietro la pipeline è quella di simulare una specie di catena di montaggio industriale. La pipeline è realizzabile solo se è possibile separare un task complesso in molti task più piccoli e semplici. Anche nel caso della pipeline siamo limitati dallo stadio più lento. Il tempo della singola istruzione, quindi, non cambia e può anche peggiorare ma traiamo benefici dalla parallelizzazione di più stadi. Possiamo dire che aumentiamo il throughput, ma non la latenza delle singole istruzioni.

L'incremento di velocità introdotto con il pipelining è intaccato da più fattori:

- Durata sbilanciata dei vari stadi: limitazione per lo stadio più lento
- Tempo di "load" e "flush" della pipeline: affinché la pipeline sia a pieno regime serve del tempo, stessa cosa per lo svuotamento.




Figure 16: Schema del processore a ciclo singolo

Il pipelining è completamente trasparente al programmatore in quanto ogni singola istruzione viene ancora eseguita in modo sequenziale.

Il MIPS suddivide un'istruzione in un massimo di 5 stadi:

1. **IF**: Instruction Fetch
2. **ID**: Instruction Decode
3. **EX**: Esecuzione
4. **MEM**: Accesso alla memoria
5. **WB**: Scrittura a registri

Ciò significa che serviranno 4 stadi per caricare e svuotare la pipeline. Inoltre, ogni stadio ha una durata prefissata chiamata ciclo di pipeline sufficientemente lunga da consentire l'esecuzione dello stadio più lento. Le istruzioni non possono saltare stadi (come anche nell'architettura multiciclo).

Il caso ideale abbiamo che:

- La latenza della singola istruzione viene peggiorata: una **load** da 800ps in sequenziale diventa di 1000ps con pipeline (ciclo di 200ps)
- Il throughput migliora fino a 4 volte (per un numero infinito di istruzioni), quindi una istruzione di **load** viene eseguita ogni 200ps

In condizioni ideali (stadi bilanciati), quindi, il tempo trascorso tra due istruzioni sarà:

$$T_{pipe} = \frac{T_{nopipe}}{N_{stadi}}$$

La suddivisione di un'istruzione in più stadi implica che in un solo ciclo di clock saranno in esecuzione fino a 5 stadi diversi. Servono quindi dei registri interstadio che separano i vari stadi. Inoltre la struttura della CPU deve essere suddivisa in 5 parti, ciascuna corrispondente a ogni singolo stadio.

La presenza di registri interstadio richiede la presenza di un tempo di stabilizzazione dell'uscita del registro in entrata alla logica combinatoria e di un altro tempo di stabilizzazione della logica combinatoria stessa. Inoltre, i registri usabili dall'utente devono essere sincronizzati al fronte di discesa in mezzo al clock, invece di quello di salita, per garantire lettura e scrittura consistente tra i vari stadi.

Anche nell'architettura a pipeline è presente una unità di controllo e dei segnali di controllo che governano i vari multiplexer, le memorie e l'ALU. Essi sono invariati rispetto alla CPU a singolo ciclo. Unica differenza è che i segnali che servono ai vari stadi vanno salvati nei registri interstadio corrispondenti.

Conflitti nella pipeline

Esistono 3 tipi di conflitti che possono succedere:

1. Conflitto strutturale: tentativo di usare la stessa risorsa da parte di diverse istruzioni in modi diversi nello stesso intervallo di tempo (memoria singola)
2. Conflitti sui dati: tentativo di usare un risultato prima che esso sia pronto (istruzione che dipende dal risultato di un'istruzione precedente)
3. Conflitti sul controllo: tentativo di prendere una decisione sulla prossima istruzione da eseguire prima che la condizione sia valutata (istruzioni di salto condizionato)

Nel MIPS è impossibile ottenere conflitti strutturali in quanto la memoria dati e la memoria contenente le istruzioni sono separate. Inoltre il banco di registri viene usato nello stesso ciclo di clock in modo coerente con la tecnica di temporizzazione.

Conflitto sui dati

Consideriamo il seguente codice:

```
add $s0, $t0, $t1
sub $t2, $s0, $t3
```

Si può notare che il risultato corretto è disponibile anche nella fase **EX** dell'istruzione **add**. Per risolvere il conflitto, quindi, ci basterà aggiungere il cosiddetto circuito di propagazione/bypassing che collega l'uscita dello stadio **EX** con i suoi ingressi (propagazione EX/EX).

Nel seguente codice, invece

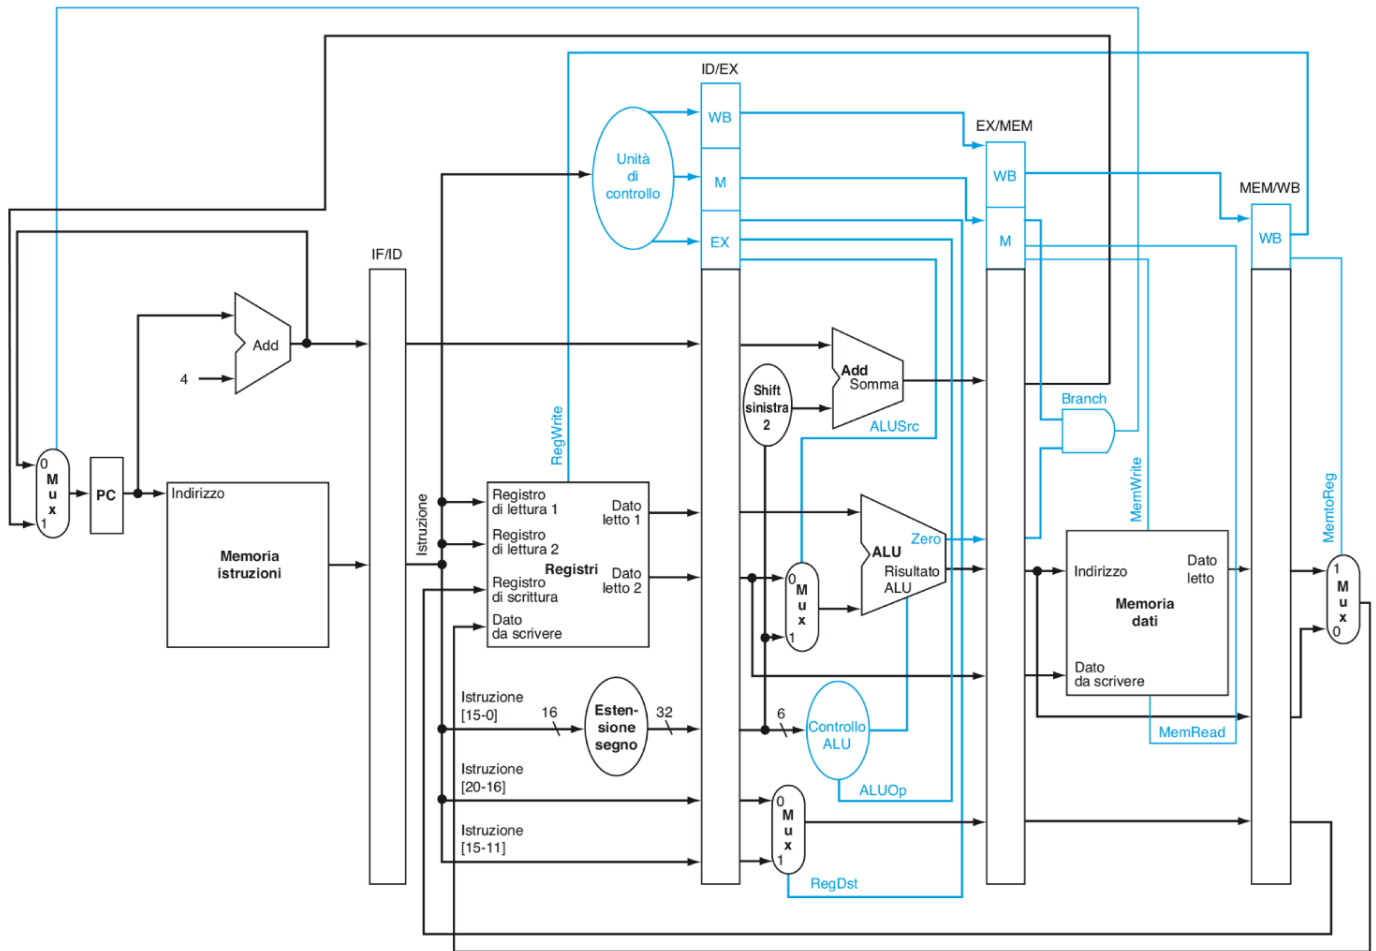


Figure 17: Schema del processore con pipeline

```
lw $s0, 20($t1)
sub $t2, $s0, $t3
```

Il circuito di propagazione EX/EX non basta poiché il risultato corretto sarà caricato in `$s0` solo nella fase WB. Andrà inserito un altro circuito di propagazione che collega l'uscita della fase MEM con l'ingresso della fase EX. Però, al momento dell'esecuzione di MEM, la fase EX dell'istruzione precedente sarà già stata eseguita. Bisogna quindi aggiungere anche un ciclo di ritardo nell'esecuzione di sub per permettere l'allineamento di MEM ed EX. Questo ritardo sarà dato dalla cosiddetta NOP (no operation).

Le soluzioni disponibili per la risoluzione dei conflitti di dati sono le seguenti:

- A livello di compilazione:
 - Inserimento di istruzioni NOP
 - Scheduling o riordino delle istruzioni in modo da impedire che istruzioni correlate siano troppo vicine: il compilatore inserisce delle operazioni indipendenti dal risultato delle precedenti operazioni o NOP nel caso non ci siano istruzioni di questo tipo
- A livello hardware:
 - Inserimento di stalli nella pipeline: lo stallo viene creato propagando 0 in tutti i segnali di controllo.
 - Propagazione di dati in avanti (forwarding o bypassing): vengono resi accessibili alle istruzioni successive i dati quando sono ancora nei registri interstadio, prima che essi vengano scritti nei registri.

La soluzione preferita saranno le soluzioni a livello hardware.

Propagazione di dato

Quando un'istruzione nel suo stadio EX deve utilizzare un dato di un registro che non è ancora stato scritto da un'istruzione precedente della sua fase di WB è necessario portare il dato all'ingresso corretto della ALU.

Le coppie di condizioni che generano un conflitto di dato sono:

1. EX/MEM.RegistroRd == ID/EX.RegistroRs: conflitto in EX
2. EX/MEM.RegistroRd == ID/EX.RegistroRt: conflitto in EX
3. MEM/WB.RegistroRd == ID/EX.RegistroRs: conflitto in MEM
4. MEM/WB.RegistroRd == ID/EX.RegistroRt: conflitto in MEM

Per quanto riguarda l'implementazione, aggiungeremo dei multiplexer in entrata agli ingressi dell'ALU (con corrispondenti segnali di controllo) in modo da permettere all'ALU di usare il contenuto dei registri interstadio.

La propagazione avviene solo se:

- il segnale `RegWrite` viene asserito nello stadio del conflitto, quindi tra i segnali di controllo WB negli stadi EX/MEM o MEM/WB
- il registro di destinazione non è il registro 0

L'unità di controllo della propagazione esegue i seguenti controlli (pseudo codice):

```
PropagaA = 0;
PropagaB = 0;

if (EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRs))
    PropagaA = 0x10; // MUX PA

if (EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRt))
    PropagaB = 0x10; // MUX PB

if (MEM/WB.RegWrite && (MEM/WB.RegRd != 0) && (MEM/WB.RegRd == ID/EX.RegRs))
    PropagaA = 0x01; // MUX PA

if (MEM/WB.RegWrite && (MEM/WB.RegRd != 0) && (MEM/WB.RegRd == ID/EX.RegRt))
    PropagaB = 0x01; // MUX PB
```

Queste condizioni sono, però, ancora incomplete in quanto può svilupparsi il conflitto sul quale valore sia più recente. Si dovrà impedire che due istruzioni successive condividano lo stesso registro tra registro sorgente e destinazione:

```
add $1, $1, $1
add $1, $1, $2 # Rd == Rs
```

Riscriviamo le condizioni per riflettere questi cambiamenti:

```

PropagaA = 0;
PropagaB = 0;

if (EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRs))
    PropagaA = 0x10; // MUX PA

if (EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRt))
    PropagaB = 0x10; // MUX PB

if (MEM/WB.RegWrite && (MEM/WB.RegRd != 0) &&
    !(EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRs))
    && (MEM/WB.RegRd == ID/EX.RegRs))
    PropagaA = 0x01; // MUX PA

if (MEM/WB.RegWrite && (MEM/WB.RegRd != 0) &&
    !(EX/MEM.RegWrite && (EX/MEM.RegRd != 0) && (EX/MEM.RegRd == ID/EX.RegRt))
    && (MEM/WB.RegRd == ID/EX.RegRt))
    PropagaB = 0x01; // MUX PB

```

Quindi la propagazione dello stadio MEM/WB avviene solo se non esiste una conflitto con EX/MEM.

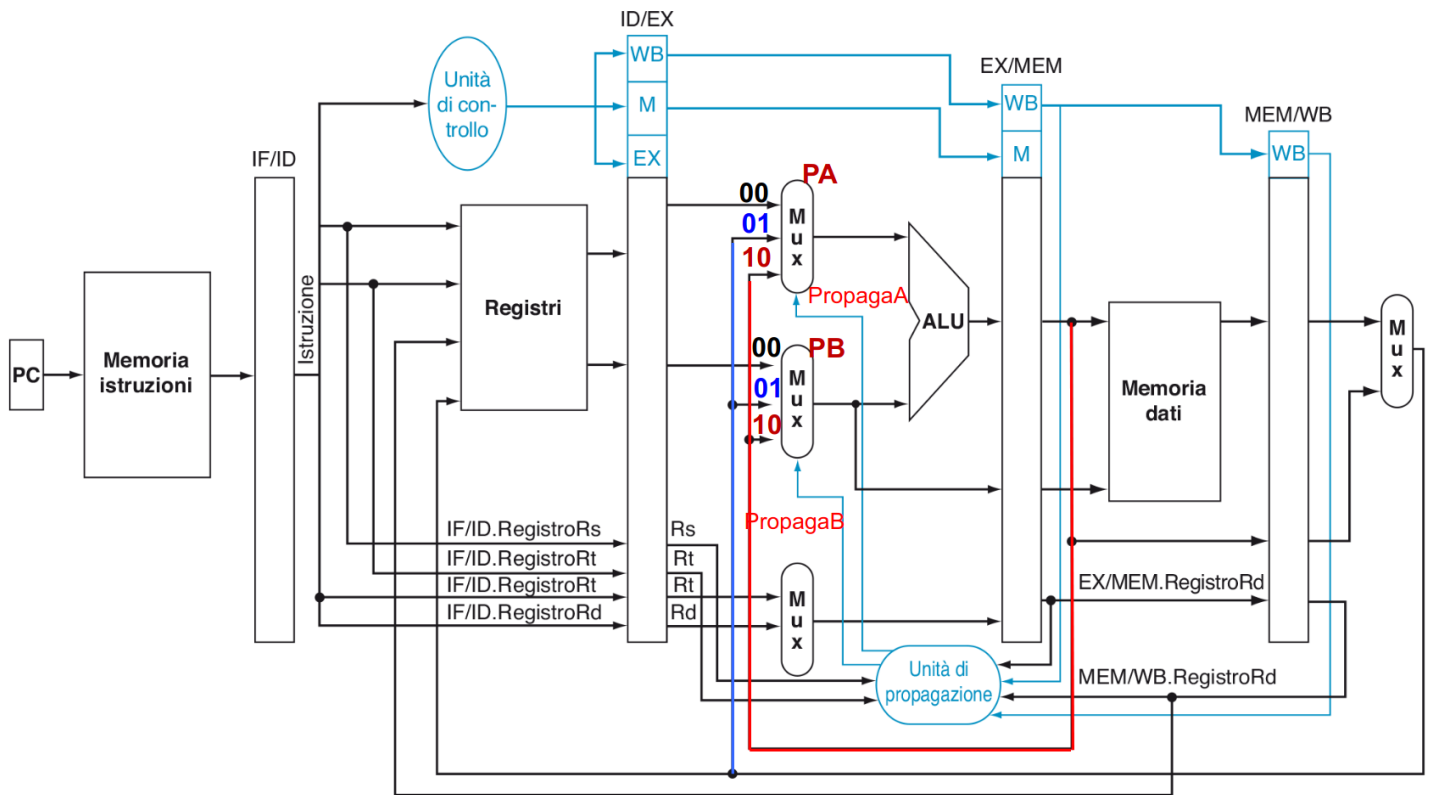


Figure 18: Modifiche per usare la propagazione

Nonostante le nostre condizioni, rimane ancora il problema delle **load/store**. Dovremmo aggiungere un ulteriore cammino di propagazione tra i due stadi MEM, anch'esso comandato dall'unità di propagazione.

Rimane ancora il caso del **load/use**. Questo caso non è risolvibile senza uno stallo.

Stallo

In aggiunta all'unità di propagazione, aggiungiamo un'altra unità di rilevamento dei conflitti che durante lo stadio di ID possa inserire uno stallo.

Lo stallo viene eseguito azzerando tutti i segnali di controllo emanati dall'unità di controllo. Inoltre l'unità di rilevazione dei conflitti controlla la scrittura del program counter.

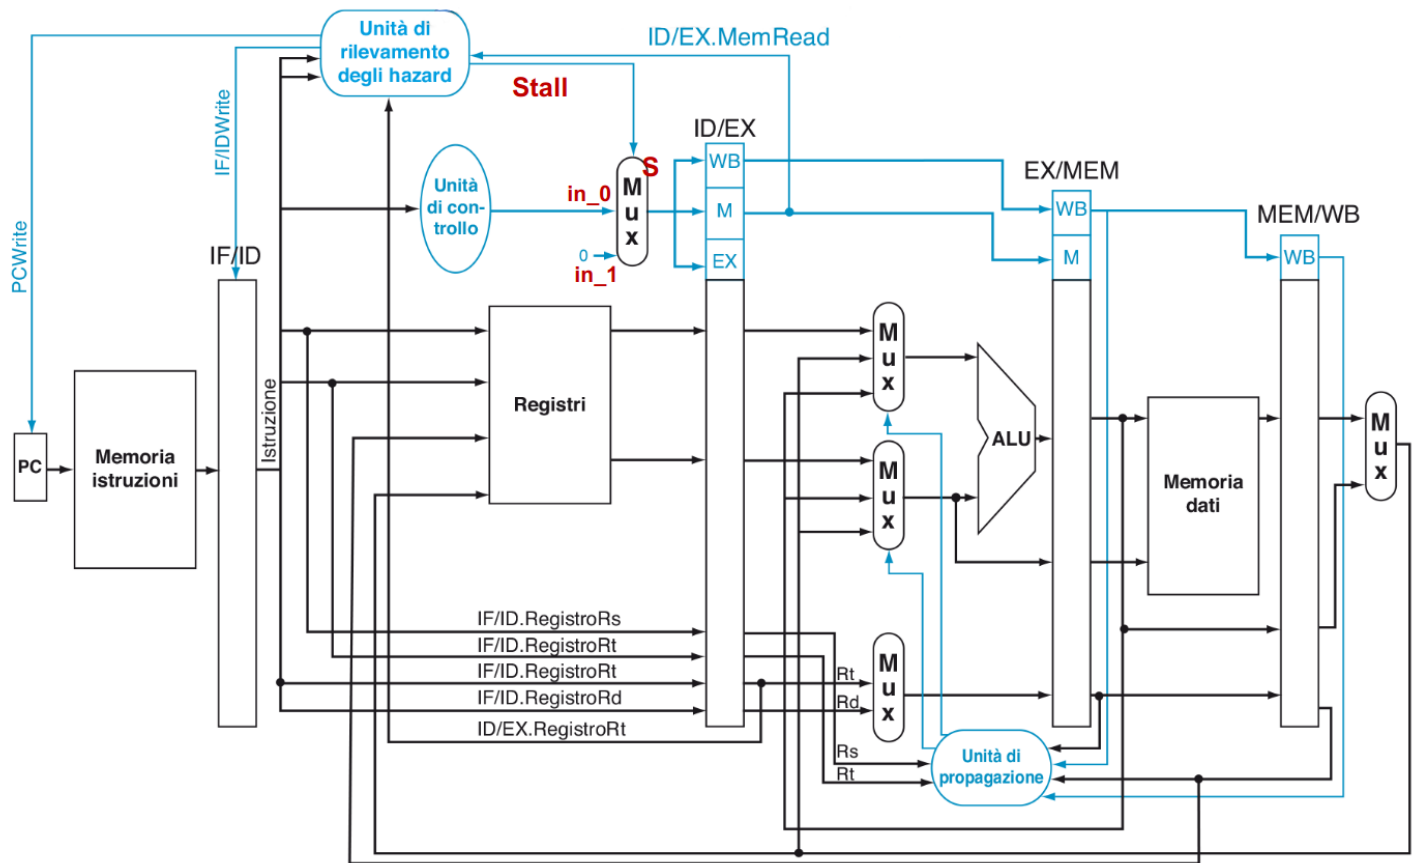


Figure 19: Modifiche per usare lo stallo

Prendendo in esame il caso *load/use*, il conflitto verrà rilevato confrontando la *ID/EX* della *load* e la *IF/ID* della *use*:

```
if (ID/EX.MemRead &&
    ((ID/EX.RegRt == IF/ID.RegRs) || (ID/EX.RegRt == IF/ID.RegRt)))
    StallPipeline();
```

Quindi, se leggo la memoria e la destinazione della *load* e la sorgente della *use* coincidono, la pipeline verrà stallata.

Conflitto di controllo

Per alimentare la pipeline si deve prelevare un'istruzione ad ogni ciclo di clock, però la decisione relativa al salto condizionato non viene presa fino allo stadio *MEM*. La logica di controllo del salto viene determinata nello stadio *MEM* e, sul fronte di salita del ciclo corrispondente, nel program counter viene scritto l'indirizzo di destinazione del salto. Questo ritardo nel determinare l'istruzione corretta da prelevare viene chiamato conflitto di controllo o conflitto di salto condizionato. Questi conflitti sono statisticamente meno frequenti dei conflitti sui dati.

Come soluzione a questo tipo di conflitto possiamo usare diverse strategie:

1. Utilizzo della predizione:

Viene sempre presa l'ipotesi che il salto non venga eseguito. Se il salto dovrà essere eseguito verrà inserito uno stallo nella pipeline per scartare le istruzioni erroneamente eseguite (2 nel caso di pipeline non ottimizzata, 1 altrimenti).

2. Utilizzo della pipeline ottimizzata:

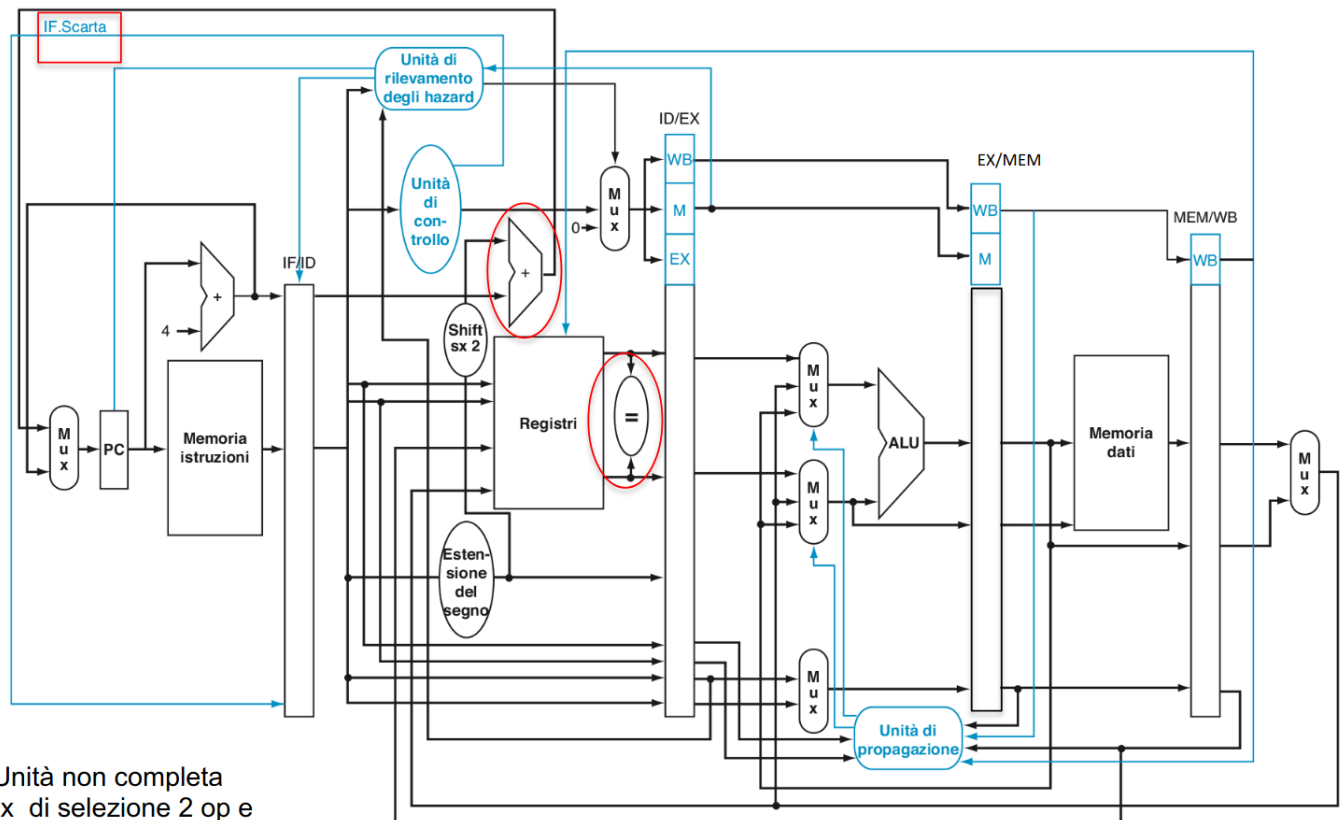
Si sposta la decisione del salto da *MEM* a uno stadio precedente. Possiamo:

- Anticipare il calcolo della destinazione del salto: basterebbe spostare il sommatore che calcola l'indirizzo di salto da *EX* a *ID* senza molte modifiche
- Anticipare la decisione sul salto: è necessario confrontare il contenuto dei due registri letti nello stadio *ID* tramite un confrontatore (si esegue lo *XOR* bit a bit; se è zero i due valori sono uguali e basta negare l'uscita per ottenere il segnale). Poi è necessario propagare il valore del confronto fino allo stadio *EX* (*ID/EX.Zero*) per poter generare correttamente *PcSrc*. La logica del salto viene, quindi, spostata in *EX*.

Ci sono dei problemi legati a questa soluzione per quanto riguarda il conflitto sui dati: se il dato da confrontare è calcolato dall'istruzione precedente il valore non è reperibile nella fase di codifica della nostra branch. La soluzione sarebbe aggiungere un nuovo cammino di propagazione tra EX e ID per effettuare il calcolo corretto se la branch dipende da un'istruzione situata due istruzioni prima e stallare se dipende da quella precedente.

Useremo la seconda ottimizzazione in quanto ci permette di ridurre la penalità di un salto condizione a un solo ciclo di clock.

Se il salto viene eseguito, è necessario scartare l'istruzione nella fase di fetch. Per fare ciò, viene aggiunto un altro segnale di controllo chiamato **IF.Scarta** che azzerla la parte del registro IF/ID che contiene l'istruzione, rendendola una NOP.



Nota: Unità non completa
del mux di selezione 2 op e
controllo ALU

Figure 20: Modifiche per gestire il salto condizionato (schema quasi completo)

La gerarchia delle memorie

L'obiettivo è:

- dare l'illusione di una memoria grande, veloce e poco costosa
- I programmi possano accedere a uno spazio di memoria che scala fino alla dimensione del disco a una velocità pari a quella dell'accesso a registro
- Fornire al processore i dati alla velocità in cui è in grado di elaborarli

Per ottenere ciò si usa una gerarchia di memoria, ossia diversi livelli di memorie realizzate con tecnologie diverse. Noi studieremo la gerarchia a due livelli.

Il processore lavorerà solo con il primo livello, quello più veloce. Se il dato non è presente in quel livello, allora il processore preleverà il blocco dai livelli superiori e lo salverà nel primo.

I livelli sono: (dal più alto e veloce al più basso e lento)

- Registri
 - Scambia istruzioni con la cache
 - gestito da programmatore/compiler
- Cache
 - scambia blocchi con la memoria centrale

- gestito dal controllore della cache
- Memoria centrale
 - scambia pagine con il disco
 - gestito dal sistema operativo
- Disco
 - scambia file con i supporti esterni
 - gestito dall'utente
- Supporti esterni

Memoria Cache

La memoria centrale e la memoria cache sono organizzate in blocchi di parole o di byte di ugual dimensione. La memoria cache contiene copie di blocchi della memoria centrale oppure blocchi liberi. Ad ogni blocco è associato un bit di validità che indica se il blocco è significativo o libero.

Il sistema di gestione della cache è in grado di:

- copiare blocchi della memoria centrale alla memoria cache
- ricopiare blocchi dalla memoria cache alla memoria centrale

Il processore accede prima alla memoria cache e poi alla memoria centrale. La cache è indirizzata con gli stessi indirizzi della memoria centrale. La cache è, quindi, trasparente al programmatore/assembler.

Funzionamento per le istruzioni:

1. Il processore deve leggere un'istruzione
2. Se il blocco è in cache, l'istruzione viene prelevata in un solo clock. Se il blocco non è in cache, il processore va in stallo per numero variabile di clock finché l'istruzione non viene copiata dalla memoria centrale nella cache.

In lettura di dati il processore funziona come per le istruzioni. Per la scrittura si possono usare diverse strategie: scrittura differita (scrivo prima in cache e poi in centrale) o non differita (mantengo cache e RAM sincronizzati).

L'uso della memoria cache per incrementare le prestazioni del sistema di memoria sfrutta il principio di località dei programmi:

- località spaziale: vengono trasferiti in cache più parole di quante non ne siano richieste (linea di cache).
- località temporale: viene sfruttata quando si deve scegliere il blocco da sostituire nella gestione di un fallimento. Si tenta, quindi, di mantenere i dati a cui si è fatto accesso più di recente vicino al processore.

Definizioni

- Hit: accesso a dati presenti in un blocco di cache
 - Hit rate: numero di accessi che trovano il dato in cache rispetto al numero totale di accessi
 - Hit time: tempo per accedere al dato in cache
- Miss: accesso fallito in cache, i dati devono essere recuperati in memoria centrale
 - Miss Rate: $1 - (HitRate)$
 - Miss Penalty: tempo necessario a sostituire un blocco in cache e accedervi

Organizzazione delle memoria cache

Si differenziano per:

- metodo di indirizzamento
- metodo di identificazione
- metodi di scrittura
- metodo di sostituzione

Cache a indirizzamento diretto

Indirizzamento (cache a indirizzamento diretto)

L'indirizzo del blocco di cache viene calcolato con la seguente semplice formula:

$$indirizzo_{mem} \bmod size_{cache}$$

Più indirizzi possono essere caricati nello stesso blocco in cache. Si possono verificare, quindi, dei conflitti. Consideriamo il seguente esempio:

Cache da 2^3 blocchi (3 bit di indirizzo) e 2^5 blocchi di memoria centrale. A ogni blocco di cache corrisponderanno $2^5/2^3 = 2^2$ blocchi di memoria centrale.

Ogni blocco di memoria centrale viene mappato con i 3 bit meno significativi del suo indirizzo. I bit rimanenti vengono usati per risolvere i conflitti e vengono chiamati etichetta.

Quindi, per risolvere i conflitti, si deve mantenere una tabella ausiliaria contenente tutte le etichette dei vari blocchi. Come nell'esempio, le etichette corrisponderanno agli n bit più significativi degli $n + k$ bit dell'indirizzo.

La limitazione di questa modalità di indirizzamento è che la cache inizierà a fallire ben prima che la cache sia piena.

Identificazione (cache a indirizzamento diretto)

Poiché nel MIPS usiamo parole di 4 byte e dobbiamo riuscire a indirizzare il singolo byte, dobbiamo anche sfruttare le informazioni che l'indirizzo ci può fornire:

- B bit per indirizzare il byte
- K bit per indirizzare la riga di cache
- $N - (K + B)$ come etichetta

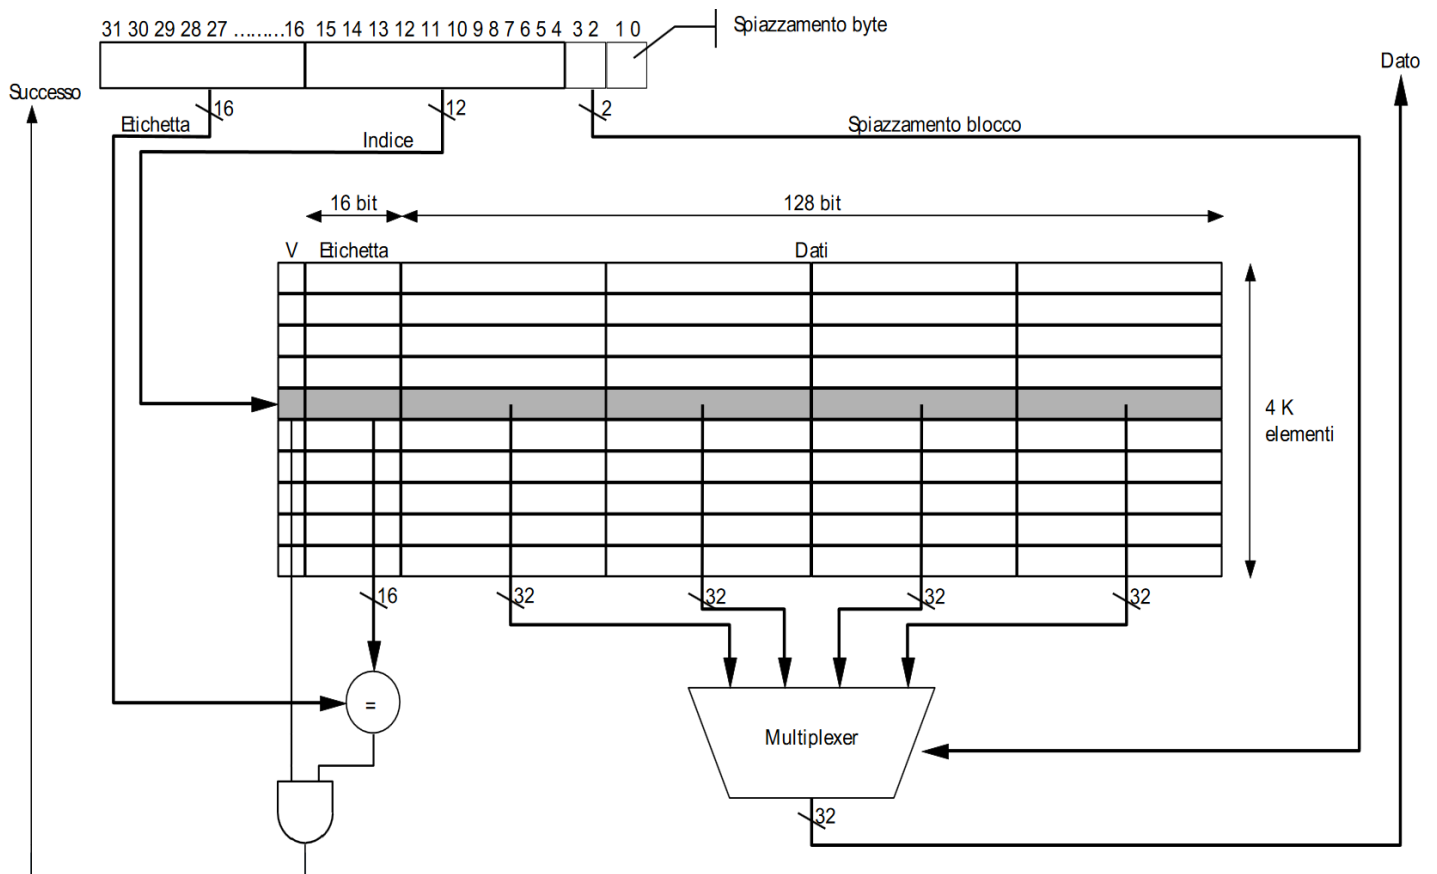


Figure 21: Funzionamento della cache a indirizzamento diretto

Si può notare che i dati arrivano al processore prima del segnale di `hit`. Il processore dovrà, quindi, bloccare i dati mentre aspetta l'arrivo del segnale di controllo.

Strategia di scrittura (cache a indirizzamento diretto)

La gestione delle hit e delle miss in lettura scrittura sarà la seguente:

	Lettura	Scrittura
Hit	Presente in cache	<ul style="list-style-type: none"> • Sostituzione del dato sia in cache che in memoria (write-through) • Scrittura del dato solo nella cache (write-back) con copia in memoria in un secondo momento

	Lettura	Scrittura
Miss	<ul style="list-style-type: none"> • Stallo della CPU • Richiesta del blocco contenente il dato dalla memoria • Copia in cache • Ripetizione dell'operazione di lettura 	<ul style="list-style-type: none"> • Stallo della CPU • Richiesta del blocco contenente il dato dalla memoria • Copia in cache • Ripetizione dell'operazione di scrittura

La durata dello stallo non ha un numero ben definito di cicli. Bisogna quindi:

1. Attivare il segnale di stallo
2. Inviare il valore corretto dell'indirizzo dell'istruzione da caricare alla memoria e scrittura nel program counter
3. Richiesta di lettura in memoria e attesa della risposta
4. Il controllore della cache gestisce il caricamento in cache del dato
5. Segnalazione all'unità di controllo della pipeline del caricamento
6. Riesecuzione della fetch dell'istruzione

Sostituzione (cache a indirizzamento diretto)

La sostituzione dei blocchi non usati è risolta automaticamente dalla modalità di indirizzamento.

Dimensionamento (cache a indirizzamento diretto)

Abbiamo quindi:

- 32 bit di indirizzo
- 2^n blocchi con n i bit dell'indirizzo necessari per l'indice
- ogni blocco sarà 2^{m+2} byte con m bit per individuare la parola all'interno del blocco
- Dimensione etichetta: $32 - (n + m + 2)$

Il totale di bit sarà:

$$2^n * (dim_{blocco} + dim_{etichetta} + 1)$$

Cache completamente associativa

A un indirizzo di memoria centrale può corrispondere qualunque indirizzo di cache. Non esiste, quindi, una relazione tra indirizzo di memoria del blocco in cache e di conseguenza il problema del mapping.

Con un indirizzo di N bit e blocchi di cache lunghi 2^M byte usiamo:

- M bit meno significativi dell'indirizzo per identificare il blocco della cache.
- $N - M$ bit più significativi di etichetta

La ricerca di un dato nella cache richiede il confronto di tutte le etichette presenti in cache. Per aumentare le prestazioni la ricerca avviene in parallelo tramite una memoria associativa dal costo elevato. A causa di questo elevato costo non vengono utilizzate spesso.

In caso di miss si agisce alla stessa maniera delle altre cache. Se la cache è piena, il blocco da sostituire può essere scelto:

- in modo casuale
- in base all'ultimo utilizzo

Cache set-associative

Indirizzamento (cache set-associativa)

E' una via di mezzo tra i due metodi precedenti. I blocchi di cache sono divisi in n gruppi (set). La cache viene indirizzata per gruppi. Ogni gruppo contiene almeno $2n$ blocchi di cache. Ogni blocco di memoria può essere caricato in un solo gruppo e in uno degli n blocchi.

La cache set-associativa in cui un blocco può andare in n posizioni viene chiamata set-associativa a n vie.

Identificazione (cache set-associativa)

Abbiamo detto che ogni blocco di memoria centrale corrisponde ad un unico gruppo della cache ed il blocco può essere messo in uno qualsiasi degli elementi di questo gruppo.

L'indirizzo di memoria di n bit è diviso in 4 campi:

- B bit meno significati individuano il byte all'interno della parola
- K bit individuano la parola all'interno del blocco
- M bit individuano il gruppo (indirizzamento diretto per il gruppo)
- $N - (M + K + B)$ come etichette (completamente associativa nel gruppo)




Figure 22: Funzionamento di una cache set-associativa a 4 vie

Strategie di scrittura (cache set-associativa)

Come nella cache a indirizzamento diretto.

Sostituzione

Come nella cache completamente associativa:

- casuale
- LRU (Least Recently Used):
 - Cache a 2 vie: Esiste un bit di uso per ogni blocco dell'insieme: quando un blocco viene usato questo bit vale 1, altrimenti 0
 - Cache a 4 vie: Esiste un contatore di uso per ogni blocco dell'insieme: quando un blocco viene utilizzato il suo contatore viene messo a 0, gli altri incrementati di 1. Per limitare i ritardi si usa un bit di uso per ogni blocco.

Confronto tra diverse organizzazione di cache

Confrontiamo la cache set-associativa a n vie e la cache a indirizzamento diretto (la cache completamente associativa non è in meta):

	Set-associativa	Indirizzamento diretto
Comparatori	n	1
Ritardo	Ritardo aggiuntivo dovuto ad un MUX aggiuntivo per dati	Minimo

	Set-associativa	Indirizzamento diretto
Disponibilità dati	Dopo il segnale di hit	Prima del segnale di hit . E' possibile ottimizzare e prevedere una hit, recuperando in caso di fallimento

Strategie di scrittura di un blocco

Abbiamo anticipato le due strategie utilizzabili per gestire una scrittura in cache:

- write-through - L'informazione viene scritta sia nel blocco di livello superiore che nel blocco di livello inferiore. Il vantaggio consiste che fallimenti in lettura non si tramutano in scritture in memoria
- write-back - L'informazione viene scritta solo nel blocco di livello superiore. Il livello inferiore viene aggiornato solo in caso di sostituzione. Questo significa che:
 - Per ogni blocco di cache è necessario mantenere l'informazione sulla scrittura
 - Ad ogni blocco è associato un bit di modifica che indica se il blocco è stato modificato
 - Non si hanno aggiornamenti ripetuti delle stesse celle di memoria

Prestazioni

Le prestazioni vengono calcolate come tempo di accesso medio alla memoria. Esso si calcola come:

$$AMAT = Hit_{time}[s] + MissRate[1] * MissPenalty[cicli]$$

Cache multilivello

Al giorno d'oggi i processori possiedono diversi livelli di cache:

- L1: è la più piccola e separa dati e istruzioni in due blocchi separati
- L2 e L3: è leggermente più grande e sono ad uso generale

Generalmente le cache L1 e L2 sono private di ciascun core mentre la L3 è condivisa.